


研究论文

增强机器学习预测模型对老年ICU COPD合并呼吸衰竭患者谵妄的预测:一项基于MIMIC-IV的回顾性研究

吴¹, 江有利², 李帅帅³, 李³

¹中国深圳深圳中医院(广州中医药大学第四临床医学院)护理科, ²中国深圳龙华人民医院神经内科, ³中南大学湘雅第二医院临床护理教研室, 长沙, 中国

* 202015211066@stu.usc.edu.cn

摘要

背景与目的

老年慢性阻塞性肺疾病(COPD)和呼吸衰竭患者入住重症监护病房(ICU)预后较差, 谵妄的发生进一步恶化预后并增加住院费用。本研究旨在建立该患者人群谵妄的预测模型, 并确定相关危险因素

方法

机器学习模型的数据来自MIMIC-IV数据库。使用Lasso回归和最佳子集方法进行特征变量筛选。四种模型——k近邻、随机森林、逻辑回归和极端梯度增强(XGBoost)——经过训练和优化, 以预测谵妄风险。使用十倍交叉验证来评估模型的稳定性, 使用准确性、F1分数、精度和召回率来评估模型在验证集上的有效性。使用SHapley加性解释(SHAP)方法来解释模型中每个变量的重要性。

结果

2008年至2019年期间, 共有1155名入住重症监护病房的患者被纳入该研究, 谵妄发病率为12.9%(149/1155)。在评估的4种ML模型中, XGBoost模型表现出了最好的判别能力。在验证集中, 该方法的AUC为0.932, 正确率、精密度、召回率和F1得分分别为0.891、0.839、0.795和0.810, 表明该方法具有优异的性能。通过SHAP分析确定的主要特征包括格拉斯哥昏迷量表(GCS)口头评分、住院时间、ICU入院第一天的平均SpO₂、

开放获取

引用本文: Wu Z-b, 江有利, 李S-s, 李A(2025)老年ICU COPD合并呼吸衰竭患者谵妄的增强机器学习预测模型:基于MIMIC-IV的回顾性研究. PLoS ONE 20(3): e0319297. <https://doi.org/10.1371/journal.pone.0319297>

编辑: Chiara Lazzeri, Azienda Ospedaliero Universitaria Careggi, ITALY
收稿日期: 2024年6月2日
接收日期: 2025年1月30日
发布日期: 2025年3月20日

版权所有: ©2025吴等。这是一篇基于知识共享署名许可(Creative Commons Attribution License)条款发布的开放获取文章, 在注明作者和来源的前提下, 允许在任何媒介上不受限制地使用、分发和复制。

数据可用性声明: 本研究中使用的公共数据集可通过 <https://physionet.org/content/mimiciv/2.0/> 访问和获取。研究人员将需要注册一个账户, 完成伦理审查并填写申请表才能访问数据库。本次研究的所有代码可通过访问 https://github.com/leo124coder/COPD_delirium 获取。

经费:作者未获得本研究的专项经费。

利益竞争:作者已声明不存在利益竞争。

肾脏疾病饮食改变(MDRD)方程评分、平均舒张压、GCS运动评分、性别和无创通气持续时间。这些发现为个体化风险管理提供了有价值的见解。

结论

建立的预测模型可有效预测ICU老年COPD合并呼吸衰竭患者谵妄的发生。该模型可以辅助临床决策, 潜在地改善患者预后并降低医疗成本。

1. 介绍

慢性阻塞性肺疾病(COPD)在中国是一项重大的公共卫生挑战, 其特征是持续的呼吸道症状和气流阻塞。中国40岁及以上人群的COPD患病率约为11.6%。该疾病呈慢性进行性病程, 常伴有共病。呼吸衰竭是COPD的一种常见且严重的并发症, 严重影响患者预后, 并与bbb患者62%的死亡率相关。这些危重患者需要加强监测和及时干预, 需要在重症监护病房(ICU)而不是普通病房进行管理。谵妄以注意力、意识和认知的波动性障碍为特征, 在COPD合并呼吸衰竭患者中发病率为21.94%。这种情况会带来严重的后果, 包括术后跌倒、住院时间延长、功能恢复不良、再入院率增加、非家属出院、长期认知能力下降和更高的死亡率[6-8]。Xu等人证明谵妄是ICU入院后COPD患者长期和短期死亡的独立危险因素。此外, Kerber等人发现COPD与谵妄之间存在关联, 并强调其是ICU意外出院的独立预测因素。因此, 应特别注意ICU COPD患者的谵妄。尽管其影响显著, 但谵妄的药物治疗选择仍然有限。然而, 早期识别高危患者并及时干预可以改善那些发生谵妄的呼吸衰竭患者的预后。先前的研究已经确定有创机械通气、镇静药物和保护性约束是谵妄b[12]的重要危险因素, 但这些干预措施在ICU环境中是必不可少的。谵妄的早期识别和干预仍然是医疗保健提供者面临的挑战。机器学习是人工智能的关键组成部分, 通过利用大型临床数据集进行回归和分类等预测任务, 在预测临床结果方面显示出前景。它在医学上的应用已经迅速扩大, 在icu的血源性感染、应激损伤和脓毒症预后等领域显示出良好的预测准确性[14-17]。然而, COPD合并呼吸衰竭患者ICU谵妄早期预警模型的研究仍然有限。在较早的一项研究中, Wassenaar等人采用多元逻辑回归建立了ICU患者谵妄的E-PRE-DELIRIC预测模型, 在验证数据集[18]中实现了0.75的AUC (95% CI 0.71-0.79)。随着机器学习技术在医学领域的应用越来越多, 针对特定目标人群正在开发更多的谵妄预测模型。Ren等人利用随机森林算法为大面积烧伤术后患者开发了谵妄预测模型, 在外部验证中取得了稳健的表现, 准确率为77.12%, 灵敏度为67.74%, 特异性为80.46%[19]。Lee等人开发了非心脏手术后谵妄的预测模型, 使用

XGBoost, 纳入5个变量, 在外部验证bb0中获得了0.867(0.845-0.877)的AUROC。这些研究强调了机器学习在促进临床疾病早期诊断和预防方面的巨大潜力。研究表明, 慢性无创机械通气(chronic noninvasive mechanical ventilation, NIV)已成为COPD合并呼吸衰竭患者的主要治疗方法之一。然而, Zhang等人发现谵妄与许多不良结局(NIV失败、ICU死亡率和住院死亡率)的增加有关, 因此, 在这一人群中早期预防和治疗谵妄对于改善患者bbb的长期预后是必要的。

考虑到ICU合并呼吸衰竭的COPD患者谵妄的高发生率及其相关的不良预后, 迫切需要一种可靠的早期预警模型。本研究旨在建立一种基于机器学习的ICU老年COPD呼吸衰竭患者谵妄风险预测模型, 并确定该人群谵妄的关键危险因素。利用来自公共数据库的广泛可靠的临床数据, 我们的研究结果旨在作为临床医生辅助决策的有价值的工具。

2. 材料和方法

2.1. 数据来源

本研究利用了公开可用的MIMIC-IV v2.0数据库的数据, 该数据库包含了哈佛医学院贝斯以色列女执事医疗中心(BIDMC)收治的19万多名患者的临床记录, 涵盖了2008年至2019年的45万例住院治疗。该数据库包括患者人口统计、实验室检测、药物、生命体征、外科手术、疾病诊断、药物管理和随访生存状态等综合信息。为了保护患者隐私并遵守法律法规, MIMIC数据库中的数据已进行了匿名化处理, 包括删除了任何可能识别患者身份的信息。

2.2. 参与者

本研究纳入年龄 ≥ 65 岁的COPD合并呼吸衰竭的ICU患者。所有纳入的患者都有生命体征、实验室检查以及呼吸支持的类型和持续时间的可用数据。如图1所示, 65岁以下的患者以及诊断为精神疾病或创伤性脑损伤的患者被排除在外。我们提取了首次ICU住院的记录, 并根据住院期间谵妄的ICD-9或ICD-10诊断代码将患者分为谵妄和非谵妄组。

2.3. 变量选择

我们使用SQL Server 2012安装MIMIC数据库, 利用SQL查询提取老年COPD合并谵妄患者入院ICU 24小时内的人口统计学、临床特征和实验室结果。在数据提取过程中, 根据先前的研究和临床专业知识选择变量, 预测因子包括(a)人口统计信息:年龄、性别、婚姻状况、保险、种族和体重。(b) ICU第一天的临床评分: SOFA、APS III、SIRS、GCS各维度评分。(c) ICU第一天生命体征:心率、收缩压(SBP)、舒张压(DBP)、平均动脉压(MAP)、呼吸频率、SpO₂、尿量。(d) ICU入院第一天实验室检查结果的最大值和最小值:PH、PO₂、PCO₂、BE、Total CO₂、肾小球滤过率(GFR, 使用MDRD方程计算)、血小板Wbc(白细胞)、阴离子间隙(AG)、HCO₃、血尿素氮(Bun)、钙(血尿素氮)和Bun(血尿素氮)。尿素含量




图1。流程图。

<https://doi.org/10.1371/journal.pone.0319297.g001>

氮、钙、国际标准化比值(INR)、凝血酶原时间(PT)、部分凝血活酶时间(PTT)、红细胞压积(红细胞压积)、血红蛋白(血红蛋白)和葡萄糖平均值。(e)住院期间血清肌酐(Scr)最大值和最小值。几乎所有患者在进入ICU 24小时内都要进行一系列的实验室检查、生命体征记录和监测，并由专业人员使用量表进行评估。为了寻求尽可能全面的变量纳入和筛选，我们选择了一般化的变量，以及MIMIC IV中缺失值较少的变量。

2.4. 统计分析

使用Shapiro-Wilk检验评估连续变量的正态性。正态分布变量表示为均值和标准差，非正态分布变量表示为中位数(四分位间距, IQR)。两组之间的比较酌情使用Student's t检验或Wilcoxon秩和检验进行。分类变量以计数和百分比表示，组间比较采用卡方检验。缺失值超过10%的变量被排除，剩余的缺失值使用基于随机森林的多重imputation进行估算。为了解决负组和正组之间的类不平衡问题，采用了合成少数过度抽样技术(SMOTE)来平衡数据集。数据集以80/20的比例分成训练集和验证集。特征选择

采用Lasso回归和最佳子集法, 所选变量详见S1文件。使用两个特征组合来训练模型。采用了四种机器学习算法: K近邻(KNN)、随机森林(RF)、极端梯度增强(XGBoost)和传统逻辑回归。采用十倍交叉验证评估模型性能, 并根据受试者工作特征曲线下面积(AUC-ROC)进行比较。模型在验证集上的性能使用四个指标进行评估: 准确性、F1分数、精度和召回率。利用SHAP技术[23]对模型变量进行解释。所有分析均使用R 4.3.2版本进行。

3. 结果

3.1. 患者特点

共有1155名患者从公开的MIMIC-IV 2.0数据库中被确定并纳入。筛选过程详见图1。排除丢失数据超过10%的变量, 包括心肌标记物。选择65个预测变量进行模型构建, 包括年龄、体重、住院时间、临床评分、生命体征、通气方式和实验室检查。将患者分为两组: 谵妄组($n = 146$)和非谵妄组($n = 1009$)。基线特征汇总于S1表。谵妄组患者平均年龄较大(78.5 ± 7.6 岁比 76.9 ± 7.8 岁), 男性比例较高(59.6% 比 40.4%)。两组患者住院时间和ICU住院时间($P < 0.001$), SOFA和APS III评分($P < 0.05$)均有显著差异。合并症、婚姻状况、体重、保险等方面差异无统计学意义($P < 0.05$)。

3.2. 特征筛选和模型训练

在补充材料中详细介绍了特征筛选过程, 采用了LASSO和最优子集法两种方法。这两种方法共识别了34个变量和9个变量组合。在模型训练过程中, GCS变量被认为是最不重要的, 被排除在外。与9个变量的模型相比, 8个变量的XGBoost模型表现出更高的性能和更低的复杂性。因此, 我们通过纳入8个变量来优化子集回归。基于这些结果, 我们构建了数据集并对数据进行了分区。采用knn、RF、XGBoost和lr四种算法在训练集上进行模型训练和参数优化。采用十倍交叉验证对模型进行评价(图2A, B)。4个模型在测试集上的平均AUC分别为0.787、0.690、0.831和0.921, 其中XGBoost模型的AUC最高, 稳定性较好。此外, 在验证集上, XGBoost模型显示出最高的AUC(图2C, D), 以及在准确性(0.891), F1分数(0.810), 精度(0.839)和召回率(0.795)方面的优越性能(图3)。

3.3. 模型选择和特征解释

经过模型比较, 选择使用最优子集方法开发的XGBoost模型进行特征优化。采用SHAP分析进行全局模型解释(图4A), 给出特征重要性排序(图4B)。结果表明, GCS口头、住院时间、平均SpO₂、平均DBP和MDRD方程是模型的前五大贡献者。单个模型特征的依赖关系图说明了它们之间的相互作用。GCS言语评分(格拉斯哥昏迷量表言语反应)的SHAP值分布在其范围内。颜色梯度代表性别, 深色表示女性, 浅色表示男性, 这表明




图2。机器学习模型的比较。(A) KNN、RF、LR、XGBoost的十倍交叉验证平均AUC (Lasso回归);(B) KNN、RF、LR、XGBoost(最佳子集选择)的十倍交叉验证平均AUC;(C) KNN、RF、LR、XGBoost的AUC-ROC曲线(Lasso回归);(D) KNN、RF、LR、XGBoost(最佳子集选择)的AUC-ROC曲线。

<https://doi.org/10.1371/journal.pone.0319297.g002>

对GCS口头SHAP值的潜在性别相关影响。住院天数的SHAP值呈正趋势，表明住院天数越长，模型的预测值越高。颜色梯度表示GCS口头评分，这意味着格拉斯哥昏迷量表口头评分也影响住院天数的SHAP值。此外，SHAP被用于个人层面的局部解释，如图5A和b所示。这种个性化的风险评估阐明了该模型预测谵妄风险的能力。低风险患者(预测风险评分:-2.48)主要受平均舒张压和平均手指脉搏血氧饱和度等因素的影响。相反，高风险患者(预测风险评分:1.69)主要受住院时间和性别的影响。这种可解释性为有针对性的风险管理提供了有价值的见解。决策曲线分析(DCA)的




图3. 四种机器学习模型在Test Dataset上的Accuracy、F1 Score、Precision和Recall的比较。

<https://doi.org/10.1371/journal.pone.0319297.g003>

测试数据集表明，基于预测建模的干预产生了良好的结果(图6)。

4. 讨论

本研究利用MIMIC-IV数据建立了icu中老年COPD合并呼吸衰竭患者谵妄的预测模型。我们的模型在验证集上显示出很高的准确性和可靠性。虽然与34变量模型相比，简化后的模型性能略有下降，但其较低的复杂性显著降低了实施成本，提高了通用性，使模型更适合临床使用。我们使用SHAP可视化技术来解释模型中每个变量的重要性并对其进行排序。该预测模型可以无缝集成到现有的ICU工作流程中，使医疗保健提供者能够快速识别高风险患者并实施预防措施，最终改善患者的治疗效果并降低医疗保健成本。

我们采用了两种特征选择技术:Lasso回归和最优子集回归。Lasso回归包含了更多的变量，并产生了良好的预测精度，而最优子集回归在更少的变量下获得了相似的精度。在测试的模型(KNN、RF和LR)中，XGBoost在所有评估指标中都取得了最高的性能。这突出了XGBoost对这项任务的适用性，特别是在处理ICU环境中典型的复杂非线性关系时。Lasso和最优子集回归的有效性验证了我们的方法，确保了高预测能力和计算效率。

尽管机器学习具有显著的优势，但大多数模型的功能都是黑盒，这使得它们难以使用传统的线性方法进行解释，并引起了临床医生的关注。SHAP为模型解释提供了一种手段。SHAP值




图4。基于shap的模型解释。(A) SHAP汇总点阵图。较高的SHAP值表明谵妄的可能性增加。点表示患者的SHAP值, 用特征值着色(黄色代表高, 紫色代表低);(B) XGBoost模型中变量的重要性排序。主要特征包括平均舒张压(Db p min)和肾小球滤过率(MDRD est)。(C)模型中各种特征的SHAP值图。SHAP值阐明了每个特征对模型输出的影响。每个子图说明了特定特征与其SHAP值之间的关系, 其他特征值由颜色梯度表示。

<https://doi.org/10.1371/journal.pone.0319297.g004>




图5. 使用SHAP方法解释局部模型，包括瀑布图和每个特征对个体风险的演变，被分为低(A)或高(B)风险的谵妄老年人：“A”表示个体不属于“谵妄”类别，而“B”表示个体属于“谵妄”类别。

<https://doi.org/10.1371/journal.pone.0319297.g005>

量化每个特征的贡献，这有助于临床工作人员更好地理解预测模型并进行相应的干预[24]。我们通过采用SHAP对XGBoost模型进行全局和局部解释来缓解这一挑战。此外，我们确定GCS语言评分、住院时间、第一天平均SpO₂、MDRD方程、第一天平均舒张压、GCS运动评分、性别和无创通气持续时间是COPD合并呼吸衰竭患者谵妄的关键预测因素。我们的发现与先前的研究一致，即住院时间、GCS评分和无创通气是谵妄的关键危险因素[25,26]。值得注意的是，所选择的变量(不包括实验室测试)在常规临床实践中很容易获得，从而降低了实施障碍并提高了通用性。专注于可访问的临床数据使我们的模型能够无缝集成到ICU工作流程中，促进及时和具有成本效益的干预措施。这种方法与现有研究一致，研究表明，基于常规临床变量的实用模型可以实现较高的预测准确性，并改善患者预后。未来的研究应探索该模型在不同患者亚组(包括不同年龄范围、性别和不同合并症患者)中的适用性，以进一步验证其泛化性。

专门针对老年COPD伴呼吸衰竭患者谵妄的研究是有限的。Li及其同事确定年龄、BMI、高血压、APACHE II评分、CPOT、镇静和PaO₂是该人群中谵妄的关键因素[10]。虽然有价值，但由于预测精度较低，他们的研究传统的分析方法限制了临床适用性。我们的研究在此基础上结合了先进的机器学习技术，提高了谵妄预测的准确性。在先进的机器学习框架中利用这些风险因素，我们的模型提高了预测性能和临床实用性。尽管许多研究利用机器学习开发了ICU患者谵妄风险的预测模型，但大多数模型的表现并不充分。Kim等人开发了ICU患者的基本预测模型，在测试集[27]中实现了0.779 (CI 0.748-0.811)的AUROC，而我们的预测模型在验证集中实现了0.932的AUROC。这种差异可能是由于ICU患者的个体差异，他们经常出现复杂的情况并接受不同的治疗。专注于特定的疾病亚组可能会提高模型的预测性能。Zhang等人开发了一种风险预测模型




图6。预测模型的决策曲线分析(DCA)。

<https://doi.org/10.1371/journal.pone.0319297.g006>

退行性脊柱疾病患者术后谵妄的九种算法。结果表明，XGBoost算法表现出最好的性能，其AUC为0.879 (CI: 0.819-0.940)[28]，与我们的研究结果相似。这强调了XGBoost算法在构建预测模型方面的优越性。XGBoost因其出色的性能、鲁棒性、正则化和可解释性而广泛应用于实际应用中。这一方法学上的进步克服了以往研究的局限性，增强了谵妄风险评估在icu中的实际适用性，有可能实现更早、更有效的干预。Huang A. A[30]使用XGBoost、随机森林、人工神经网络和自适应boost四种算法对英国国家卫生服务心脏病预测队列数据进行建模，其中XGBoost算法脱颖而出，构建模型的AUROC范围为0.771 ~ 0.947。显示出其强大的潜力，与我们的研究相似。

Dodsworth等人开发的PIPRA工具在预测老年患者[31]术后谵妄(POD)的外部验证中，AUC为0.74(0.68-0.80)。

同样，Song等人的模型对POD[32]的AUC为0.71。我们的模型AUC为0.921，超过了这些基准，特别是对于患有COPD和呼吸衰竭的ICU患者。这证明了我们的模型的有效性和可靠性，并且之前未被发现的COPD合并呼吸衰竭患者谵妄风险的预测模型为该领域的ICU提供者提供了一个有价值的工具，通过及时干预来改善患者的预后。

值得注意的是，我们的最终模型包括了患者第一天的GCS语言和运动评分。GCS评分广泛用于评估患者意识，与谵妄影响意识有关。同样，Wang等人建立了ICU患者48小时内谵妄发生的预测模型，最终纳入的特征包括入院第一天的GCS评分，这证明了在ICU入院24小时内评估GCS评分对于早期识别谵妄的重要性[33,34]。Tang等人的研究也提供了MIMIC IV期老年ICU患者谵妄的早期预测，并显示GCS评分、机械通气和镇静是前三个最重要的影响特征，再次说明GCS在谵妄早期识别中的重要性。Bodien等人指出，GCS总分可能不能准确反映意识水平，并建议考虑个体量表行为[36]。我们的研究通过强调GCS子量表，特别是GCS言语评分在谵妄预测中的关键作用，从而简化评估过程并提高其实用性，从而加强了这一观点。

在本研究中，与其他算法相比，XGBoost显示出更好的预测能力和准确性。经典逻辑回归的表现相对较差。相反，Song等人的一项研究发现，逻辑回归在预测术后谵妄[37]方面优于复杂的机器学习算法，这与我们的研究结果不同。这些差异可能是由于变量特征和数据分布的变化。Feng等人观察到类似的发现，指出机器学习算法在预测大型复杂数据集[38]的结果方面表现出色。然而，与传统的预测模型相比，XGBoost模型的黑箱特性可能使其不那么直观，尽管SHAP方法大大减少了这一缺点，但传统医疗保健从业者可能仍然没有认识到这一点。因此，在构建风险预测模型时，应用各种训练策略并根据评估指标选择合适的算法至关重要。

本研究有几个局限性。首先，这是一项回顾性研究。尽管我们的模型在使用MIMIC数据集的内部验证集上表现良好，但这些数据来自美国，缺乏跨不同人群的外部验证。因此，需要在前瞻性队列中验证其实际预测效果。其次，我们纳入的生命体征和实验室结果仅限于患者入住重症监护室后24小时内的情况。由于不同人员收集这些数据所使用的技术和方法不同，数据之间可能存在一定的偏差，影响了在临床应用的有效性。此外，患者指标在住院过程中会发生变化，这在我们的研究中没有考虑到。未来医院技术的进步可能会使谵妄风险基于住院时间的动态评估成为可能，从而允许在不同阶段制定量身定制的干预策略。

5. 结论

我们优化的XGBoost模型具有较高的准确性和可靠性，利用了常规护理中容易获得的关键临床变量。这种实用且可推广的模型可以有效地集成到ICU工作流程中，从而实现及时且具有成本效益的干预措施。利用先进的机器学习技术，我们的研究解决了先前研究的局限性，并增强了临床决策和患者预后。未来研究

应优先考虑不同设置的外部验证，并调查其他预测因素，以增强模型的适用性。总的来说，我们的研究为谵妄的早期识别和干预提供了一个有价值的工具，其目标是改善患者的预后和降低医疗成本。

支持性信息

S1表。MIMIC-IV数据库数据集中谵妄和非谵妄患者的特征。

(PDF格式)

S1文件。变量筛选过程(套索与最佳子集回归)(PDF文件)

作者贡献

数据管理:蒋友利。

形式分析:蒋友利, 李帅帅。 **写作-原**

稿:吴宗弼。 **写作-审编:**敖李。

参考文献

1. Chen J, Yin Y, Zhang Y, Lin X, Chen T, Yang Z, et al. Chronic obstructive pulmonary disease prevalence and associated risk factors in adults aged 40 years and older in Southeast China: A cross-sectional study during 2019–2020. *Int J Chron Obstruct Pulmon Dis*. 2022;17:2317–28. <https://doi.org/10.2147/COPD.S377857> PMID: 36159656
2. Negewo NA, Gibson PG, McDonald VM. COPD and its comorbidities: Impact, measurement and mechanisms. *Respirology*. 2015;20(8):1160–71. <https://doi.org/10.1111/resp.12642> PMID: 26374280
3. Hardang IM, Søyseth V, Kononova N, Hagve T-A, Einvik G. COPD: Iron deficiency and clinical characteristics in patients with and without chronic respiratory failure. *Chronic Obstr Pulm Dis*. 2024;11(3):261–9. <https://doi.org/10.15326/jcopdf.2023.0477> PMID: 38575374
4. Ai L, Zhang J, Bo W. Respiratory failure in intensive care unit patients with progressive COPD: Nursing approaches to patient care. *Altern Ther Health Med*. 2022;28(1):52–7. PMID: 34264863
5. Fu X, Wang L, Wang G, Liu X, Wang X, Ma S, et al. Delirium in elderly patients with COPD combined with respiratory failure undergoing mechanical ventilation: a prospective cohort study. *BMC Pulm Med*. 2022;22(1):266. <https://doi.org/10.1186/s12890-022-02052-5> PMID: 35810306
6. Kirfel A, Guttenthaler V, Mayr A, Coburn M, Menzenbach J, Wittmann M. Postoperative delirium is an independent factor influencing the length of stay of elderly patients in the intensive care unit and in hospital. *J Anesth*. 2022;36(3):341–8. <https://doi.org/10.1007/s00540-022-03049-4> PMID: 35182209
7. Goldberg TE, Chen C, Wang Y, Jung E, Swanson A, Ing C, et al. Association of Delirium With Long-term Cognitive Decline: A Meta-analysis. *JAMA Neurol*. 2020;77(11):1373–81. <https://doi.org/10.1001/jamaneurol.2020.2273> PMID: 32658246; PMCID: PMC7358977 McDonnell Foundation during the conduct of the study. Dr Whittington reports grants from National Institute of General Medical Sciences during the conduct of the study and personal fees from Anesthesia and Analgesia outside the submitted work. No other disclosures were reported.
8. Noufi P, Anderson KM, Crowell N, White Y, Molina E, Rao SD, et al. Prognostic implications of delirium after left ventricular assist device implantation: A retrospective study. *J Acad Consult Liaison Psychia-try*. 2024;65(6):527–36. <https://doi.org/10.1016/j.jaclp.2024.04.005> PMID: 38705515
9. Xu H-B, Xue F, Ye Y, Zhang H-G. Association of delirium with long-term mortality in critically ill patients with COPD who survived to discharge: A retrospective cohort study. *Lung*. 2024;202(5):533–41. <https://doi.org/10.1007/s00408-024-00725-y> PMID: 38914868
10. Kerber K, Zangmeister J, McNett M. Relationship between delirium and ventilatory outcomes in the medical intensive care unit. *Crit Care Nurse*. 2020;40(2):24–31. <https://doi.org/10.4037/ccn2020697> PMID: 32236430

11. Neufeld KJ, Yue J, Robinson TN, Inouye SK, Needham DM. Antipsychotic medication for prevention and treatment of delirium in hospitalized adults: A systematic review and meta-analysis. *J Am Geriatr Soc*. 2016;64(4):705–14. <https://doi.org/10.1111/jgs.14076> PMID: 27004732
12. Mart MF, Williams Roberson S, Salas B, Pandharipande PP, Ely EW. Prevention and management of delirium in the intensive care unit. *Semin Respir Crit Care Med*. 2021;42(1):112–26. <https://doi.org/10.1055/s-0040-1710572> PMID: 32746469
13. Spiegelberg J, Song H, Pun B, Webb P, Boehm LM. Early identification of delirium in intensive care unit patients: Improving the quality of care. *Crit Care Nurse*. 2020;40(2):33–43. <https://doi.org/10.4037/ccn2020706> PMID: 32236428
14. Häug CJ, Dräzen JM. Artificial intelligence and machine learning in clinical medicine. *N Engl J Med*. 2023;388(13):1201–8. <https://doi.org/10.1056/NEJMr2302038> PMID: 36988595
15. Liang Q, Ding S, Chen J, Chen X, Xu Y, Xu Z, et al. Prediction of carbapenem-resistant gram-negative bacterial bloodstream infection in intensive care unit based on machine learning. *BMC Med Inform Decis Mak*. 2024;24(1):123. <https://doi.org/10.1186/s12911-024-02504-4> PMID: 38745177
16. Xu J, Chen T, Fang X, Xia L, Pan X. Prediction model of pressure injury occurrence in diabetic patients during ICU hospitalization—XGBoost machine learning model can be interpreted based on SHAP. *Intensive Crit Care Nurs*. 2024;83:103715. <https://doi.org/10.1016/j.iccn.2024.103715> PMID: 38701634
17. Shi J, Han H, Chen S, Liu W, Li Y. Machine learning for prediction of acute kidney injury in patients diagnosed with sepsis in critical care. *PLoS One*. 2024;19(4):e0301014. <https://doi.org/10.1371/journal.pone.0301014> PMID: 38603693
18. Wassenaar A, van den Boogaard M, van Achterberg T, Slooter AJC, Kuiper MA, Hoogendoorn ME, et al. Multinational development and validation of an early prediction model for delirium in ICU patients. *Intensive Care Med*. 2015;41(6):1048–56. <https://doi.org/10.1007/s00134-015-3777-2> PMID: 25894620
19. Ren Y, Zhang Y, Zhan J, Sun J, Luo J, Liao W, et al. Machine learning for prediction of delirium in patients with extensive burns after surgery. *CNS Neurosci Ther*. 2023;29(10):2986–97. <https://doi.org/10.1111/cns.14237> PMID: 37122154
20. Lee DY, Oh AR, Park J, Lee S-H, Choi B, Yang K, et al. Machine learning-based prediction model for postoperative delirium in non-cardiac surgery. *BMC Psychiatry*. 2023;23(1):317. <https://doi.org/10.1186/s12888-023-04768-y> PMID: 37143035
21. Raveling T, Vonk J, Struik FM, Goldstein R, Kerstjens HA, Wijkstra PJ, et al. Chronic non-invasive ventilation for chronic obstructive pulmonary disease. *Cochrane Database Syst Rev*. 2021;8(8):CD002878. <https://doi.org/10.1002/14651858.CD002878.pub3> PMID: 34368950
22. Zhang R, Bai L, Han X, Huang S, Zhou L, Duan J. Incidence, characteristics, and outcomes of delirium in patients with noninvasive ventilation: a prospective observational study. *BMC Pulm Med*. 2021;21(1):157. <https://doi.org/10.1186/s12890-021-01517-3> PMID: 33975566
23. Ning Y, Ong MEH, Chakraborty B, Goldstein BA, Ting DSW, Vaughan R, et al. Shapley variable importance cloud for interpretable machine learning. *Patterns (N Y)*. 2022;3(4):100452. <https://doi.org/10.1016/j.patter.2022.100452> PMID: 35465224
24. Huang AA, Huang SY. Dendrogram of transparent feature importance machine learning statistics to classify associations for heart failure: A reanalysis of a retrospective cohort study of the Medical Information Mart for Intensive Care III (MIMIC-III) database. *PLoS One*. 2023;18(7):e0288819. <https://doi.org/10.1371/journal.pone.0288819> PMID: 37471315
25. Tabbì L, Tonelli R, Comellini V, Dongilli R, Sorgentone S, Spacone A, et al. Delirium incidence and risk factors in patients undergoing non-invasive ventilation for acute respiratory failure: a multi-center observational trial. *Minerva Anesthesiol*. 2022;88(10):815–26. <https://doi.org/10.23736/S0375-9393.22.16511-9> PMID: 35708040
26. Smith PJ, Rivelli SK, Waters AM, Hoyle A, Durheim MT, Reynolds JM, et al. Delirium affects length of hospital stay after lung transplantation. *J Crit Care*. 2015;30(1):126–9. <https://doi.org/10.1016/j.jcrc.2014.09.010> PMID: 25307975
27. Kim M-K, Oh J, Kim J-J, Park JY. Development and Validation of Simplified Delirium Prediction Model in Intensive Care Unit. *Front Psychiatry*. 2022;13:886186. <https://doi.org/10.3389/fpsy.2022.886186> PMID: 35845446
28. Zhang Y, Wan D-H, Chen M, Li Y-L, Ying H, Yao G-L, et al. Automated machine learning-based model for the prediction of delirium in patients after surgery for degenerative spinal disease. *CNS Neurosci Ther*. 2023;29(1):282–95. <https://doi.org/10.1111/cns.14002> PMID: 36258311
29. Babajide Mustapha I, Saeed F. Bioactive Molecule Prediction Using Extreme Gradient Boosting. *Molecules*. 2016;21(8):983. <https://doi.org/10.3390/molecules21080983> PMID: 27483216

30. Huang AA, Huang SY. Increasing transparency in machine learning through bootstrap simulation and shapely additive explanations. *PLoS One*. 2023;18(2):e0281922. <https://doi.org/10.1371/journal.pone.0281922> PMID: 36821544
31. Dodsworth BT, Reeve K, Falco L, Huetting T, Sadeghirad B, Mbuagbaw L, et al. Development and validation of an international preoperative risk assessment model for postoperative delirium. *Age Ageing*. 2023;52(6):afad086. <https://doi.org/10.1093/ageing/afad086> PMID: 37290122
32. Song Y, Zhang D, Wang Q, Liu Y, Chen K, Sun J, et al. Prediction models for postoperative delirium in elderly patients with machine-learning algorithms and SHapley Additive exPlanations. *Transl Psychiatry*. 2024;14(1):57. <https://doi.org/10.1038/s41398-024-02762-w> PMID: 38267405
33. Wang M-L, Kuo Y-T, Kuo L-C, Liang H-P, Cheng Y-W, Yeh Y-C, et al. Early prediction of delirium upon intensive care unit admission: Model development, validation, and deployment. *J Clin Anesth*. 2023; 88:111121. <https://doi.org/10.1016/j.jclinane.2023.111121> PMID: 37058755
34. Guo J, Cheng H, Wang Z, Qiao M, Li J, Lyu J. Factor analysis-based on SHapley-Additive exPlanations for sepsis-associated encephalopathy in ICU mortality prediction using XGBoost –A retrospective study based on two large database. *Front Neurol*. 2023;14:1290117. <https://doi.org/10.3389/fneur.2023.1290117> PMID: 38162445
35. Tang D, Ma C, Xu Y. Interpretable machine learning model for early prediction of delirium in elderly patients following intensive care unit admission: a derivation and validation study. *Front Med (Lausanne)*. 2024;11:1399848. <https://doi.org/10.3389/fmed.2024.1399848> PMID: 38828233
36. Bodien YG, Barra A, Temkin NR, Barber J, Foreman B, Vassar M, et al. Diagnosing level of consciousness: The limits of the Glasgow Coma Scale Total Score. *J Neurotrauma*. 2021;38(23):3295–305. <https://doi.org/10.1089/neu.2021.0199> PMID: 34605668
37. Song Y-X, Yang X-D, Luo Y-G, Ouyang C-L, Yu Y, Ma Y-L, et al. Comparison of logistic regression and machine learning methods for predicting postoperative delirium in elderly patients: A retrospective study. *CNS Neurosci Ther*. 2023;29(1):158–67. <https://doi.org/10.1111/cns.13991> PMID: 36217732
38. Feng J-Z, Wang Y, Peng J, Sun M-W, Zeng J, Jiang H. Comparison between logistic regression and machine learning algorithms on survival prediction of traumatic brain injuries. *J Crit Care*. 2019;54:110–6. <https://doi.org/10.1016/j.jcrc.2019.08.010> PMID: 31408805